

验证报告 / 2026-09-06

# Mini-Drop AI 诊断 与 Skill 复用测试报告

面向面试演示的功能闭环、数据集、质量门禁与证据边界

|                      |             |             |         |
|----------------------|-------------|-------------|---------|
| 540                  | 93.70%      | 404         | 72      |
| 新设计盲测 Case           | Skill 路由通过率 | Python 回归通过 | 接口路由对齐  |
| 公开 query / 私有 oracle | 506/540     | 另有 3 项跳过    | 方法/路径组合 |

**报告结论** 页面已形成可重复的演示闭环：从故障广场启动白名单故障，AI 自主发现安全目标，执行四轮树搜索、工具调用、证据裁决和报告生成，并可在同页进行多轮对话、人工干预和技能 A/B 对比。

**实机验收** 2026-09-06 云端 Python 源码热点场景通过：两条全新会话均完成 4 轮、4 次真实工具调用、16 条证据和 4 版报告，火焰图 2968 个根样本，故障停止与恢复校验通过。

**重要边界** 93.70% 只代表技能路线选择与拒绝的静态盲测，不是根因准确率；21 个故障场景已上线，但本轮只对 Python 源码热点做了完整云端 A/B 实机验收。

**版本范围** 云端发布目录 20260906T142517Z；代码来自 D:\tx\mini-drop 当前未提交工作树。

Evidence before conclusion. Route memory before repeated exploration.

1. 执行摘要

这轮改造解决的不是三个孤立的页面 Bug，而是三条演示链断点：范围确认缺少幂等语义、采集成功与样本有效性混在一起、以及诊断会话缺少可见的多轮交互。修复后的系统把用户输入视为调查上下文，把 Artifact 经过质量门禁后形成 Evidence，再由报告引用 Evidence 给出可验证结论。

| 用户看到的问题            | 根因                            | 现在的行为                                                       |
|--------------------|-------------------------------|-------------------------------------------------------------|
| 重复确认范围时报 immutable | 浏览器分钟精度与服务端秒/时区表达直接比较         | 同一 UTC 语义与页面分钟重试幂等；真实移动时间窗仍拒绝                               |
| Task DONE 却没有火焰图   | perf header-only 也可能以退出码 0 结束 | 零样本、空折叠栈、空可视化 fail-closed，并返回可行动重采提示                        |
| 总是证据不足或一直准备        | 无受控故障、无后续回合、动态树藏在回放弹窗         | 故障广场 + 多轮干预 + 主页面动态树 + 可继续调查                                |
| Skill 复用无法现场对比     | 旧页面只有离线或硬编码指标                 | AUTO/DISABLED 创建两条真实 Diagnosis，比较真实 ID、Tool、Evidence、Report |

验收判断

- 功能合同：后端、OpenAPI、故障白名单、时间窗幂等和干预事件已有自动化覆盖。
- 页面闭环：用户可以从故障广场进入诊断、在诊断中继续追问/质疑/换方向，并在同页观察探索树 revision。
- 采集可信度：以后不会再把 0 KB JSON 和空 SVG 当成成功火焰图；历史空产物需重新采集。
- 实验可信度：540-case 可以证明路由选择器的行为，不能替代真实 Linux 故障的根因评测。

2. 页面演示闭环

面试演示时，推荐按下面的因果顺序讲，而不是按菜单逐页点击：

故障广场 → 诊断会话 → 假设 → 工具调用 → 任务/产物 → 证据 → 报告 → 恢复验证

| 页面能力  | 现场动作                                    | 面试官能看到的真实性信号                                           |
|-------|-----------------------------------------|--------------------------------------------------------|
| 故障广场  | 选择 CPU、源码热点、内存、I/O、噪声邻居、负载或队列场景，限定时长并启动 | 浏览器只提交 scenario_id 与 duration；服务端固定白名单，不接收任意命令/PID/URL |
| AI 诊断 | 描述症状并让 AI 自动发现安全目标，或人工确认目标              | 诊断 ID、绑定 ID、时间窗和技能策略都由服务端持久化                           |
| 多轮对话  | 补充上下文、质疑假设、换方向、继续调查                     | 每次提交产生人工干预事件；用户话语不会直接成为证据                              |

| 页面能力   | 现场动作                       | 面试官能看到的真实性信号                     |
|--------|----------------------------|----------------------------------|
| 动态探索树  | 观察假设、探针、任务、证据和报告节点实时增加     | revision/version 增长，方向切换与人工节点可追溯 |
| 技能 A/B | 同问题分别创建“关闭技能”和“自动技能”会话     | 对比两条真实会话的技能激活、工具、证据、报告和耗时        |
| 任务结果   | 进入采集 Task 查看 Artifact 和可视化 | 空样本明确失败；有样本才渲染火焰图和 TopN          |

人工干预的四种语义

| 动作                     | 用途                     | 安全语义                  |
|------------------------|------------------------|-----------------------|
| ADD_CONTEXT            | 补充部署变更、症状、业务背景         | 只作为 Context，不升格为事实证据  |
| CHALLENGE_HYPOTHESIS   | 要求 AI 反驳当前主假设          | 保留旧假设历史，创建新的可证伪方向     |
| CHANGE_DIRECTION       | 从 CPU 转向 I/O、内存、网络或运行时 | 新探针仍经过目标绑定、能力、风险和预算门禁 |
| CONTINUE_INVESTIGATION | 证据不足或已有结论后继续一轮         | 旧报告不可变，新事件进入下一轮调查     |

云端页面实机链路

| 实验臂  | 诊断 ID                                    | 真实执行                      | 可视化与结论                               |
|------|------------------------------------------|---------------------------|--------------------------------------|
| 关闭技能 | insight_e581f5ac05704a2e96ba8a899a9786bd | 4 轮 / 4 工具 / 16 证据 / 4 报告 | 火焰图 2968 样本；TopN 8；置信度 0.69          |
| 自动技能 | insight_85bff86fb8fc4c9abd72e6e26496b77b | 4 轮 / 4 工具 / 16 证据 / 4 报告 | 火焰图 2968 样本；TopN 5；技能激活 1 次；置信度 0.73 |

- 两组绑定同一服务端签发的不可变目标；每组都重新启动同一白名单故障，并创建全新的任务、尝试、产物、证据和报告。
- 真实执行轮次为 1、2、3、4；树深度单独保存。回溯选择同层兄弟节点时，页面不会再把第三次执行误显示成第一轮。
- 两组精确重复的 LATS 事件均为 0；期望热点函数 source\_hot\_function 均被识别。
- 顺序运行可以证明路线真实执行和流程可重复，但墙钟耗时不能当作严格性能提升结论。

3. 540 条技能路由盲测

数据集使用固定种子 20260905 生成 540 条新问题。公开输入与私有答案分开保存；生成器不读取已退役的旧案例，但故障分类和正确技能来自当前目录。因此它是可复现的项目内盲测，不是外部独立数据集。




图 1 Skill 路由选择与安全拒绝指标（确定性重跑）

| 案例家族                            | 数量  | 技能通过             | 无技能基线 | 测试意图              |
|---------------------------------|-----|------------------|-------|-------------------|
| POSITIVE_REUSE                  | 360 | 334/360 (92.78%) | 0/360 | 描述足够具体时命中正确 Skill |
| MISLEADING_OR_UNDERSPECIFIED    | 90  | 82/90 (91.11%)   | 90/90 | 歧义或信息不足时应弃权       |
| CAPABILITY_OR_ENVIRONMENT_DRIFT | 90  | 90/90 (100%)     | 90/90 | 环境/能力不匹配时拒绝复用     |

指标解释

- 总体 506/540 (93.70%)：正例选择指定 Skill，负例正确弃权。
- No-Skill 基线 180/540 (33.33%)：它不是另一套 RCA Agent，只是永远不复用路线的保守下界。
- 8 个误激活全部来自误导/信息不足负例；它们是下一轮阈值和歧义门禁优化的直接样本。
- Skill 命中代表可复用的调查先验，不代表根因已被证明。

4. 火焰图为空：修复与质量门禁

原问题的关键不在前端渲染。perf script 和折叠脚本可能对 header-only 或 0 样本输入返回退出码 0；旧 Analyzer 随后生成空 root、空 TopN 和极小 SVG，任务仍被标为 DONE。新链路同时检查进程退出状态和内容质量。

| 检查点 | 拒绝条件 | 页面结果 |
|-----|------|------|
|-----|------|------|

| 检查点            | 拒绝条件                                                | 页面结果                                      |
|----------------|-----------------------------------------------------|-------------------------------------------|
| perf script    | 没有任何可解析 sample                                      | NO_PERF_SAMPLES; 提示确认 PID、权限、采样时长和目标是否在运行 |
| stack collapse | 没有正权重 folded stack                                  | NO_FOLDED_STACKS; 不生成伪火焰图                 |
| Analyzer 输出    | sample_count=0、profile_quality=UNUSABLE、可视化 0 bytes | 分析失败并保留结构化原因                              |
| Artifact 合同    | 新产物明确声明 0 样本或不可用                                    | 阻止进入 Evidence; 旧产物缺字段仅标记质量未知              |

**必须重采** 截图中的历史空 flamegraph.json / flamegraph.svg 不会被“修复成有内容”。修复保证新任务诚实失败；要看到火焰图，必须对一个确实消耗 CPU 的目标在当前 Analyzer 下重新采集。

## 5. 自动化验证结果

| 验证层            | 结果            | 覆盖内容                               | 结论     |
|----------------|---------------|------------------------------------|--------|
| Python 全量回归    | 404 通过 / 3 跳过 | 诊断、策略、分析器、合同、故障广场、时间窗、干预树          | 通过     |
| 前端交互回归         | 120/120 通过    | 多轮续诊、动态树、故障广场、真实技能 A/B、空采样提示       | 通过     |
| 生产 bundle      | build:check   | Vite 构建与入口预算；ECharts 612 kB 为非阻断提示 | 通过     |
| Go 全量回归        | go test ./... | 控制面、任务、产物与接口实现                     | 通过     |
| 接口契约对齐         | 72 组方法/路径     | Python RPC 实现与公开契约                 | 通过     |
| 静态 Skill 盲测    | 506/540       | 生产混合检索与拒绝门禁                        | 93.70% |
| 故障广场在线检查       | 21 个场景        | Python 7 / Go 4 / Java 5 / C++ 5   | 通过     |
| Linux 云端实机 E2E | PASS          | Python 源码热点、同目标 A/B、产物、证据、报告、恢复    | 通过     |

### 三层测试模型

1. 静态盲测：快速验证“该不该复用哪条路线”，适合放入 CI。
2. 受控故障合同/集成：验证白名单、状态机、幂等、人工干预、质量错误和事件投影。
3. Linux live E2E：在真实 Worker 和标注故障下，对比根因服务/指标、首条有效 Evidence 耗时、Tool Call 数、空 Profile 率和恢复验证。

本报告已完成前两层，并在云端 Linux Worker 上完成一个 Python 源码热点场景的第三层实机闭环。其余 20 个在线场景仍需逐场运行相同根因真值与恢复验收，不能用“已出现在故障广场”代替全量实机通过。

6. 面试演示脚本（8~10 分钟）

- 1. 打开 AI 诊断中的故障广场，选择“Python 源码热点”，设置 180 秒并启动。说明浏览器不能下发任意命令。
- 2. 点击“启动并诊断”，让 AI 自主选择服务端签发的安全目标和时间窗；展示 Diagnosis ID 与绑定 ID。
- 3. 先用“关闭技能”创建对照臂，记录第一个工具调用；恢复并重放同一故障，再用“自动技能”创建实验臂。
- 4. 在运行中的会话输入“CPU 样本没有主导热点，请质疑当前假设并转查 I/O 等待”。展示 intervention 节点和树 revision 增长。
- 5. 沿 Tool Call 打开 Task，查看 Attempt、Artifact、Analyzer 和 Evidence。如果样本为空，现场展示结构化质量错误与重采路径。
- 6. 打开技能 A/B 面板，对比两条真实会话的技能激活、工具数、首条证据、状态、报告版本和耗时。
- 7. 停止故障并验证服务恢复。最后打开 540-case 报告，明确它只测路线复用，不等于刚才的 live 根因链。

演示时建议主动说出的边界

- 人工输入是 Context，只有 Collector/Analyzer 产物通过质量门禁后才能成为 Evidence。
- Skill 是经过验证的调查路线记忆，不是把历史结论直接复制到新事故。
- A/B 的两个臂必须重置同一故障和负载；否则顺序运行会被时间漂移污染。
- INSUFFICIENT\_EVIDENCE 是安全结论，不是系统卡死；用户可以继续调查，但模型不能用猜测补齐证据。

7. 已知限制与下一步验收

| 限制                   | 影响                 | 下一步                          |
|----------------------|--------------------|------------------------------|
| 仅 1 个场景完成 Linux 实机闭环 | 不能外推 21 场景的整体根因准确率 | 逐场固定根因真值并运行多次 Campaign       |
| 故障广场主要是单机/单进程        | 对跨服务因果链覆盖有限        | 接入 OpenTelemetry Demo 级微服务场景 |
| A/B 两臂顺序运行           | 墙钟耗时可能受状态漂移影响      | 增加随机顺序、重复样本和显著性分析            |
| 旧 Profile 缺少质量元数据    | 兼容读取时只能标记质量未知      | 用新 Analyzer 重算或重新采集          |
| 误导负例仍有 8 次误激活        | Skill 可能在信息不足时过早介入 | 基于失败 Case 调整阈值并保留独立回归集       |

8. 复现命令与证据文件

```
python -m pytest -q # 404 passed, 3 skipped
cd web; npx vitest run --maxWorkers=1 --no-file-parallelism # 120 passed
go test ./...
```

```
python scripts/check_openapi_routes.py # 72 组
python scripts/generate_diagnosis_benchmark_v2.py
python scripts/run_diagnosis_benchmark_v2.py
python scripts/verify_interview_demo.py --scenario source-hotspot --fault-duration-seconds 180
```

| 证据              | 位置                                                                        |
|-----------------|---------------------------------------------------------------------------|
| 公开盲测输入          | benchmarks/diagnosis-v2/public/cases.json                                 |
| 私有 oracle       | benchmarks/diagnosis-v2/private/oracles.json                              |
| 机器可读结果          | web/public/report-assets/skill-evolution/benchmark-report.json            |
| 云端实机验收 JSON     | reports/ai-diagnosis/interview-demo-live-acceptance-20260906T142517Z.json |
| 验收 JSON SHA-256 | 9A8EA9DB4DF645B6F7CFD34C8A707D8E03E96FC719C604B09E320B1AC7146D3B          |
| 人类可读报告          | reports/ai-diagnosis/AI 诊断与 Skill 复用测试报告-20260906.md                      |
| 核心设计文档          | docs/AI_DIAGNOSIS.md、docs/SKILLS.md、docs/PROJECT_LEARNING_GUIDE.md        |

参考依据

- Microsoft AIOpsLab — application/task/fault/workload/evaluator 分层与 action trace 评估：  
<https://github.com/microsoft/AIOpsLab>
- AIOpsLab paper: [https://www.microsoft.com/en-us/research/wp-content/uploads/2024/10/arxiv\\_AIOpsLab.pdf](https://www.microsoft.com/en-us/research/wp-content/uploads/2024/10/arxiv_AIOpsLab.pdf)
- RCAEval — 以标注故障分别评估 root-cause service 与 indicator: <https://github.com/phamquilluan/RCAEval>
- RCAEval paper: <https://arxiv.org/abs/2412.17015>
- OpenTelemetry Demo feature flags — 可重放问题场景: <https://opentelemetry.io/docs/demo/feature-flags/>
- Chaos Mesh — 有 selector、duration 和恢复语义的受控故障: <https://chaos-mesh.org/docs/run-a-chaos-experiment/>

结论必须能沿 Report → Evidence → Artifact → Attempt → Task 反向追溯。