

验证报告 / 2026-09-06

Mini-Drop AI 诊断 与技能复用测试报告

面向面试演示的功能闭环、数据集、质量门禁与证据边界

540	93.70%	404	72
新设计盲测案例	技能路由通过率	Python 回归通过	接口路由对齐
公开问题 / 私有答案	506/540	另有 3 项跳过	方法/路径组合

报告结论 页面已形成可重复的演示闭环：从故障广场启动白名单故障，AI 自主发现安全目标，执行四轮树搜索、工具调用、证据裁决和报告生成，并可在同页进行多轮对话、人工干预和技能 A/B 对比。

实机验收 2026-09-06 云端 Python 源码热点场景通过：两条全新会话均完成 4 轮、4 次真实工具调用、16 条证据和 4 版报告，火焰图 2968 个根样本，故障停止与恢复校验通过。

重要边界 93.70% 只代表技能路线选择与拒绝的静态盲测，不是根因准确率；21 个故障场景已上线，但本轮只对 Python 源码热点做了完整云端 A/B 实机验收。

版本范围 云端发布目录 20260906T142517Z；代码来自 D:\tx\mini-drop 当前未提交工作树。

先看证据，再下结论；先复用路线，再避免重复探索。

1. 执行摘要

本轮改造解决的不是三个孤立的页面问题，而是三条演示链断点：范围确认缺少幂等语义、采集成功与样本有效性混在一起、以及诊断会话缺少可见的多轮交互。修复后的系统把用户输入视为调查上下文，把产物经过质量门禁后形成证据，再由报告引用证据给出可验证结论。

用户看到的问题	根因	现在的行为
重复确认范围时报“不可变”错误	浏览器分钟精度与服务端秒/时区表达直接比较	同一 UTC 语义与页面分钟重试幂等；真实移动时间窗仍拒绝
任务完成却没有火焰图	perf 只有表头时也可能以退出码 0 结束	零样本、空折叠栈、空可视化按失败处理，并返回可行动重采提示
总是证据不足或一直准备	无受控故障、无后续回合、动态树藏在回放弹窗	故障广场 + 多轮干预 + 主页面动态树 + 可继续调查
技能复用无法现场对比	旧页面只有离线或硬编码指标	自动/关闭技能分别创建真实诊断，比较真实 ID、工具、证据与报告

验收判断

- 功能合同：后端、OpenAPI、故障白名单、时间窗幂等和干预事件已有自动化覆盖。
- 页面闭环：用户可以从故障广场进入诊断、在诊断中继续追问、质疑和换方向，并在同页观察探索树版本增长。
- 采集可信度：以后不会再把 0 KB JSON 和空 SVG 当成成功火焰图；历史空产物需重新采集。
- 实验可信度：540 条案例可以证明路由选择器的行为，不能替代真实 Linux 故障的根因评测。

2. 页面演示闭环

面试演示时，推荐按下面的因果顺序讲，而不是按菜单逐页点击：

故障广场 → 诊断会话 → 假设 → 工具调用 → 任务/产物 → 证据 → 报告 → 恢复验证

页面能力	现场动作	面试官能看到的真实性信号
故障广场	选择 CPU、源码热点、内存、I/O、噪声邻居、负载或队列场景，限定时长并启动	浏览器只提交 scenario_id 与 duration；服务端固定白名单，不接收任意命令/PID/URL
AI 诊断	描述症状并让 AI 自动发现安全目标，或人工确认目标	诊断 ID、绑定 ID、时间窗和技能策略都由服务端持久化
多轮对话	补充上下文、质疑假设、换方向、继续调查	每次提交产生人工干预事件；用户话语不会直接成为证据

页面能力	现场动作	面试官能看到的真实性信号
动态探索树	观察假设、探针、任务、证据和报告节点实时增加	树版本持续增长，方向切换与人工节点可追溯
技能 A/B	同问题分别创建“关闭技能”和“自动技能”会话	对比两条真实会话的技能激活、工具、证据、报告和耗时
任务结果	进入采集任务查看产物和可视化	空样本明确失败；有样本才渲染火焰图和 TopN

人工干预的四种语义

动作	用途	安全语义
补充上下文	补充部署变更、症状、业务背景	只作为上下文，不升格为事实证据
质疑假设	要求 AI 反驳当前主假设	保留旧假设历史，创建新的可证伪方向
改变方向	从 CPU 转向 I/O、内存、网络或运行时	新探针仍经过目标绑定、能力、风险和预算门禁
继续调查	证据不足或已有结论后继续一轮	旧报告不可变，新事件进入下一轮调查

云端页面实机链路

实验臂	诊断 ID	真实执行	可视化与结论
关闭技能	insight_e581f5ac05704a2e96ba8a899a9786bd	4 轮 / 4 工具 / 16 证据 / 4 报告	火焰图 2968 样本；TopN 8；置信度 0.69
自动技能	insight_85bff86fb8fc4c9abd72e6e26496b77b	4 轮 / 4 工具 / 16 证据 / 4 报告	火焰图 2968 样本；TopN 5；技能激活 1 次；置信度 0.73

- 两组绑定同一服务端签发的不可变目标；每组都重新启动同一白名单故障，并创建全新的任务、尝试、产物、证据和报告。
- 真实执行轮次为 1、2、3、4；树深度单独保存。回溯选择同层兄弟节点时，页面不会再把第三次执行误显示成第一轮。
- 两组精确重复的 LATS 事件均为 0；期望热点函数 source_hot_function 均被识别。
- 顺序运行可以证明路线真实执行和流程可重复，但墙钟耗时不能当作严格性能提升结论。

3. 540 条技能路由盲测

数据集使用固定种子 20260905 生成 540 条新问题。公开输入与私有答案分开保存；生成器不读取已退役的旧案例，但故障分类和正确技能来自当前目录。因此它是可复现的项目内盲测，不是外部独立数据集。




图 1 Skill 路由选择与安全拒绝指标（确定性重跑）

案例家族	数量	技能通过	无技能基线	测试意图
应当复用	360	334/360 (92.78%)	0/360	描述足够具体时命中正确技能
误导或信息不足	90	82/90 (91.11%)	90/90	歧义或信息不足时应弃权
能力或环境漂移	90	90/90 (100%)	90/90	环境或能力不匹配时拒绝复用

指标解释

- 总体 506/540 (93.70%)：正例选择指定技能，负例正确弃权。
- 无技能基线 180/540 (33.33%)：它不是另一套根因诊断 Agent，只是永远不复用路线的保守下界。
- 8 个误激活全部来自误导/信息不足负例；它们是下一轮阈值和歧义门禁优化的直接样本。
- 技能命中代表可复用的调查先验，不代表根因已被证明。

4. 火焰图为空：修复与质量门禁

原问题的关键不在前端渲染。perf 解析和折叠脚本可能对只有表头或 0 样本的输入返回退出码 0；旧分析器随后生成空根节点、空 TopN 和极小 SVG，任务仍被标为完成。新链路同时检查进程退出状态和内容质量。

检查点	拒绝条件	页面结果
perf 解析	没有任何可解析样本	NO_PERF_SAMPLES；提示确认 PID、权限、采样时长和目标是否在运行

检查点	拒绝条件	页面结果
调用栈折叠	没有正权重折叠栈	NO_FOLDED_STACKS; 不生成伪火焰图
分析器输出	样本数为 0、质量为不可用、可视化为 0 字节	分析失败并保留结构化原因
产物合同	新产物明确声明 0 样本或不可用	阻止进入证据; 旧产物缺字段仅标记质量未知

必须重采 截图中的历史空 flamegraph.json / flamegraph.svg 不会被“修复成有内容”。修复保证新任务诚实失败；要看到火焰图，必须对一个确实消耗 CPU 的目标在当前分析器下重新采集。

5. 自动化验证结果

验证层	结果	覆盖内容	结论
Python 全量回归	404 通过 / 3 跳过	诊断、策略、分析器、合同、故障广场、时间窗、干预树	通过
前端交互回归	120/120 通过	多轮续诊、动态树、故障广场、真实技能 A/B、空采样提示	通过
前端生产构建	build:check	Vite 构建与入口预算; ECharts 612 kB 为非阻断提示	通过
Go 全量回归	go test ./...	控制面、任务、产物与接口实现	通过
接口契约对齐	72 组方法/路径	Python RPC 实现与公开契约	通过
技能路线盲测	506/540	生产混合检索与拒绝门禁	93.70%
故障广场在线检查	21 个场景	Python 7 / Go 4 / Java 5 / C++ 5	通过
Linux 云端端到端	通过	Python 源码热点、同目标 A/B、产物、证据、报告、恢复	通过

三层测试模型

- 1. 静态盲测：快速验证“该不该复用哪条路线”，适合放入 CI。
- 2. 受控故障合同/集成：验证白名单、状态机、幂等、人工干预、质量错误和事件投影。
- 3. Linux 实机端到端：在真实采集节点和标注故障下，对比根因服务或指标、首条有效证据耗时、工具调用数、空采样率和恢复验证。

本报告已完成前两层，并在云端 Linux Worker 上完成一个 Python 源码热点场景的第三层实机闭环。其余 20 个在线场景仍需逐场运行相同根因真值与恢复验收，不能用“已出现在故障广场”代替全量实机通过。

6. 面试演示脚本（8～10 分钟）

1. 打开 AI 诊断中的故障广场，选择“Python 源码热点”，设置 180 秒并启动。说明浏览器不能下发任意命令。
2. 点击“启动并诊断”，让 AI 自主选择服务端签发的安全目标和时间窗；展示诊断 ID 与绑定 ID。
3. 先用“关闭技能”创建对照臂，记录第一个工具调用；恢复并重放同一故障，再用“自动技能”创建实验臂。
4. 在运行中的会话输入“CPU 样本没有主导热点，请质疑当前假设并转查 I/O 等待”。展示人工干预节点和树版本增长。
5. 沿工具调用打开任务，查看尝试、产物、分析器和证据。如果样本为空，现场展示结构化质量错误与重采路径。
6. 打开技能 A/B 面板，对比两条真实会话的技能激活、工具数、首条证据、状态、报告版本和耗时。
7. 停止故障并验证服务恢复。最后打开 540-case 报告，明确它只测路线复用，不等于刚才的 live 根因链。

演示时建议主动说出的边界

- 人工输入是上下文，只有采集器和分析器产物通过质量门禁后才能成为证据。
- 技能是经过验证的调查路线记忆，不是把历史结论直接复制到新事故。
- A/B 的两个臂必须重置同一故障和负载；否则顺序运行会被时间漂移污染。
- INSUFFICIENT_EVIDENCE 是安全结论，不是系统卡死；用户可以继续调查，但模型不能用猜测补齐证据。

7. 已知限制与下一步验收

限制	影响	下一步
仅 1 个场景完成 Linux 实机闭环	不能外推 21 场景的整体根因准确率	逐场固定根因真值并运行多次 Campaign
故障广场主要是单机/单进程	对跨服务因果链覆盖有限	接入 OpenTelemetry Demo 级微服务场景
A/B 两臂顺序运行	墙钟耗时可能受状态漂移影响	增加随机顺序、重复样本和显著性分析
旧采样产物缺少质量元数据	兼容读取时只能标记质量未知	用新分析器重算或重新采集
误导负例仍有 8 次误激活	技能可能在信息不足时过早介入	基于失败案例调整阈值并保留独立回归集

8. 复现命令与证据文件

```
python -m pytest -q # 404 passed, 3 skipped
cd web; npx vitest run --maxWorkers=1 --no-file-parallelism # 120 passed
go test ./...
python scripts/check_openapi_routes.py # 72 组
python scripts/generate_diagnosis_benchmark_v2.py
```

```
python scripts/run_diagnosis_benchmark_v2.py
python scripts/verify_interview_demo.py --scenario source-hotspot --fault-duration-seconds 180
```

证据	位置
公开盲测输入	benchmarks/diagnosis-v2/public/cases.json
私有 oracle	benchmarks/diagnosis-v2/private/oracles.json
机器可读结果	web/public/report-assets/skill-evolution/benchmark-report.json
云端实机验收 JSON	reports/ai-diagnosis/interview-demo-live-acceptance-20260906T142517Z.json
验收 JSON SHA-256	9A8EA9DB4DF645B6F7CFD34C8A707D8E03E96FC719C604B09E320B1AC7146D3B
人类可读报告	reports/ai-diagnosis/AI 诊断与 Skill 复用测试报告-20260906.md
核心设计文档	docs/AI_DIAGNOSIS.md、docs/SKILLS.md、docs/PROJECT_LEARNING_GUIDE.md

参考依据

- Microsoft AIOpsLab — 应用、任务、故障、负载、评估器分层与动作轨迹评估：
<https://github.com/microsoft/AIOpsLab>
- AIOpsLab paper: https://www.microsoft.com/en-us/research/wp-content/uploads/2024/10/arxiv_AIOpsLab.pdf
- RCAEval — 以标注故障分别评估根因服务与根因指标: <https://github.com/phamquilluan/RCAEval>
- RCAEval paper: <https://arxiv.org/abs/2412.17015>
- OpenTelemetry Demo 场景开关 — 可重放问题场景: <https://opentelemetry.io/docs/demo/feature-flags/>
- Chaos Mesh — 有目标选择、持续时间和恢复语义的受控故障: <https://chaos-mesh.org/docs/run-a-chaos-experiment/>

结论必须能沿“报告 → 证据 → 产物 → 尝试 → 任务”反向追溯。